M5. Minería de Texto + webscraping

Clase 5. Modelado de tópicos II STM

factor~data
IDAES_UNSAM

Latent Dirichlet Allocation (LDA)

Ventajas de los modelos generativos:

- Supuestos explícitos: si el modelo falla (por ejemplo, no encuentra los tópicos correctos en un corpus bien definido) se puede chequear si es porque los datos no cumplen alguna.
- Variando esas hipótesis/supuestos se producen las extensiones de LDA
- Hoy: Structural Topic Modeling (STM)

Structural Topic Modeling (STM)

- Permitir vincular los tópicos detectados con covariables (o metadata)
- Variación de LDA => modelo generativo del conteo de palabras
- Las covariables pueden afectar la **prevalencia (*prevalence*)** de los tópicos sobre cada documento, es decir, permite que la composición de tópicos sobre cada documento varíe en función de alguna covariable
- También pueden afectar el **contenido (*content*)**, es decir, permite que la probabilidad de cada palabra de pertenecer a cada tópico se vea afectada por esas covariables.

Latent Dirichlet Allocation (LDA)

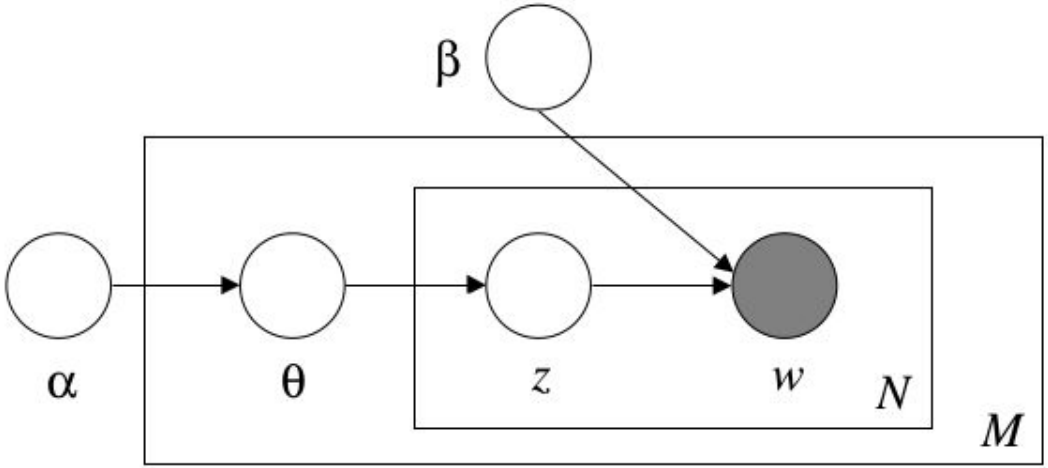

Figure 1: Graphical model representation of LDA. The boxes are "plates" representing replicates. The outer plate represents documents, while the inner plate represents the repeated choice of topics and words within a document.

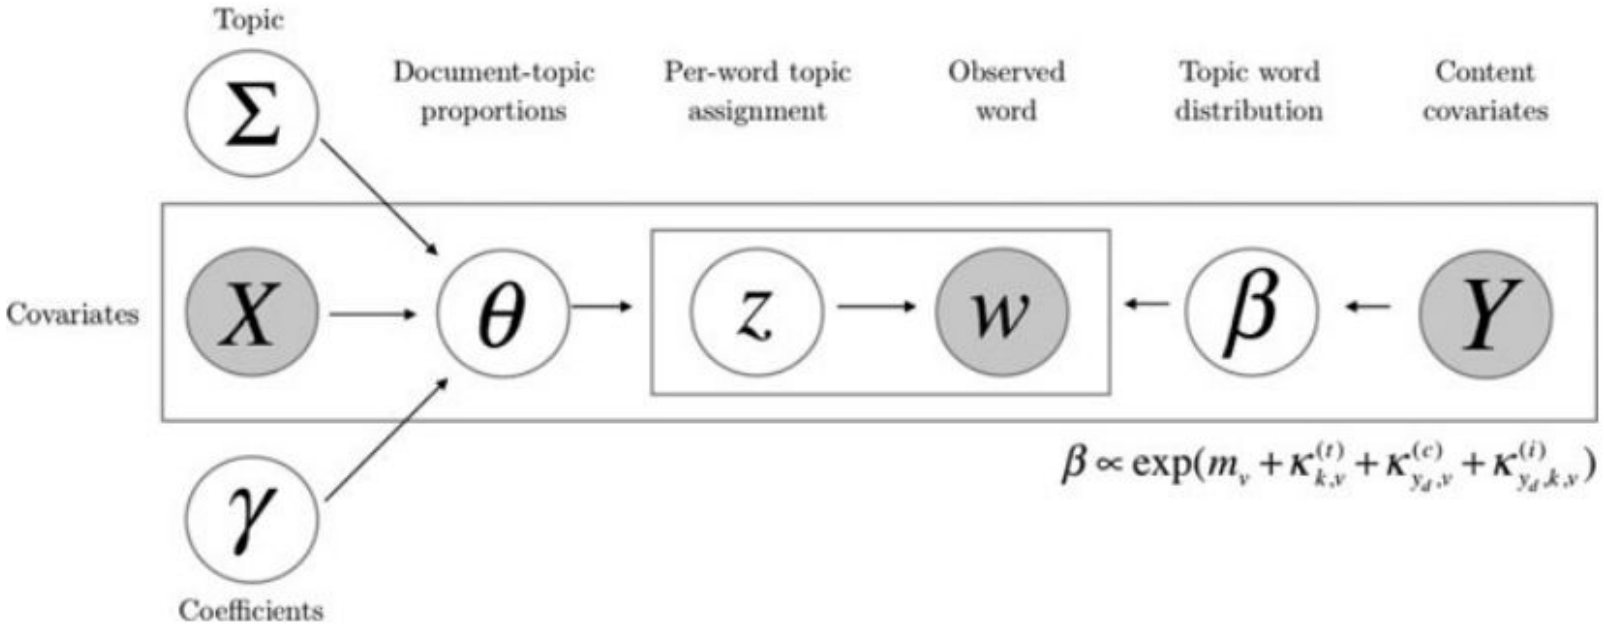
Topic
Document-topic proportions
Per-word topic assignment
Observed word
Topic word distribution
Content covariates
Covariates
Coefficients
Σ
X
θ
z
w
β
Y
γ
$\beta \propto \exp(m_v + \kappa^{(t)}_{k,v} + \kappa^{(c)}_{y_d,v} + \kappa^{(i)}_{y_d,k,v})$

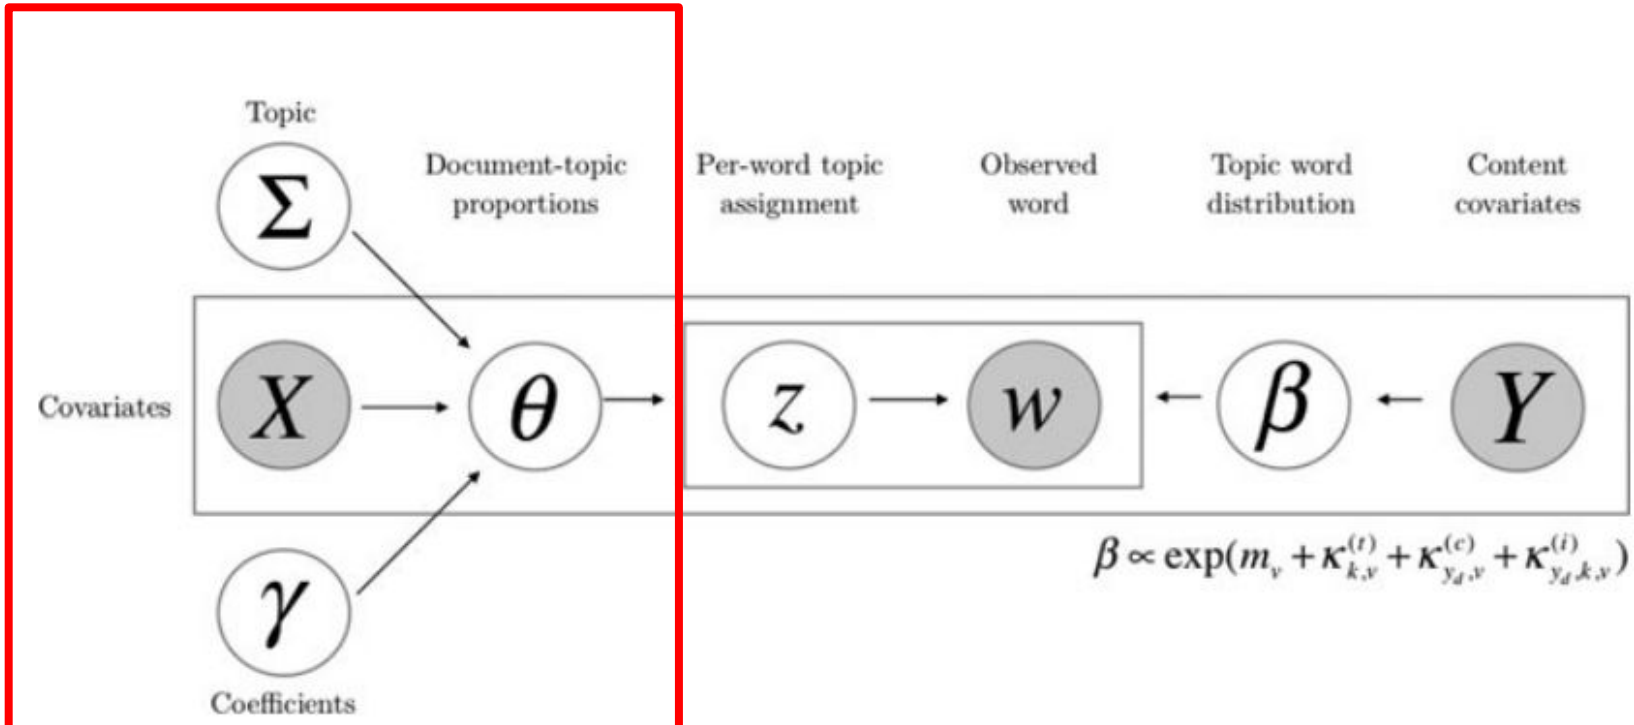

Prevalencia: X afecta a la composición de tópicos por documento

factor~data
IDAES_UNSAM

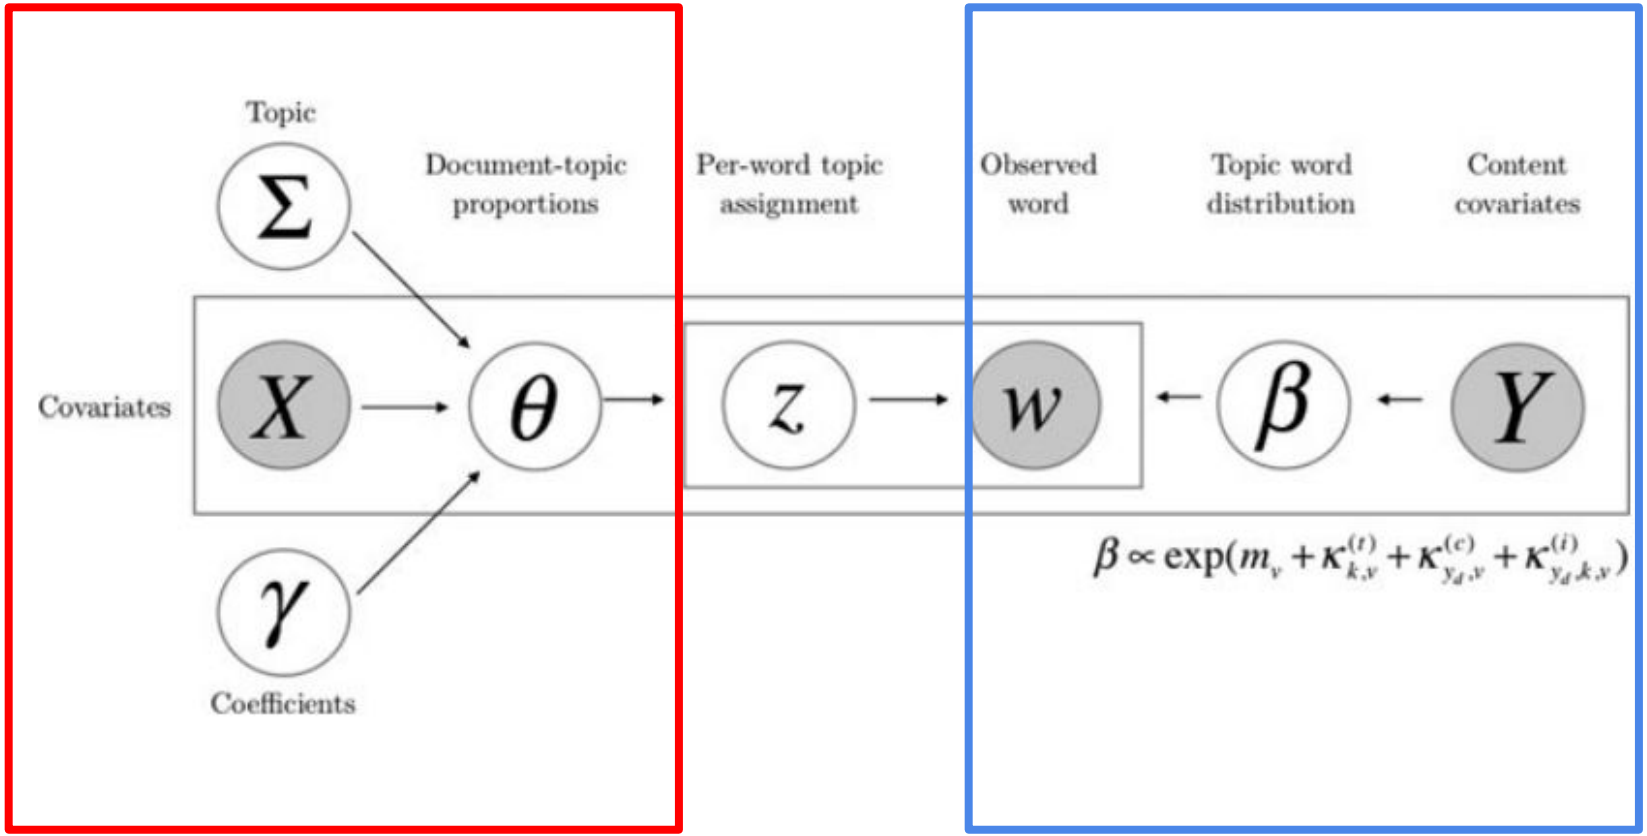

Prevalencia: X afecta a la composición de tópicos por documento

Contenido: Y afecta a la composición de palabras por tópico

Vamos al notebook...

Un flujo de trabajo posible para topic modeling

1. Definir objetivos

Adecuación entre problemas, preguntas y objetivos de investigación y supuestos del modelo (en este caso, STM/LDA u otros)

Definición conceptual de “tópico”

Ejemplo: “agenda setting”

Un flujo de trabajo posible para topic modeling

1. Definir objetivos

2. Construir un corpus

- Corpus con una distribución “balanceada”
- Evitar sesgos (o al menos conocerlos y cuantificarlos)
- Curar los corpus
- Unidad de análisis (documentos, párrafos, oraciones, etc.)

Un flujo de trabajo posible para topic modeling

1. Definir objetivos

2. Construir un corpus

3. Pre-procesar el texto

- Filtrado de palabras
  - Stopwords por lista
  - Palabras de alta frecuencia
  - Eliminar caracteres
- Reducción de complejidad (stemming/lemmatización, etc.)
- Etc.

Un flujo de trabajo posible para topic modeling

1. Definir objetivos
2. Construir un corpus
3. Pre-procesar el texto
4. Seleccionar el modelo adecuado

- K (nro. de tópicos) es el parámetro fundamental
- Dispersión de tópicos y palabras son otros opcionales
- Prueba de diferentes valores de K
- Algunas métricas (perplexity)

Un flujo de trabajo posible para topic modeling

1. Definir objetivos
2. Construir un corpus
3. Pre-procesar el texto
4. Seleccionar el modelo adecuado
5. Interpretar y validar el modelo
   - Analizar palabras por tópicos
     - Diferentes métricas (palabras más probables, FREX, etc.)
   - Muestrear documentos con altos valores en los diferentes tópicos y realizar una lectura cercana para validar
   - Colapsar tópicos similares (lógica similar a Grounded Theory)

Un flujo de trabajo posible para topic modeling

1. Definir objetivos
2. Construir un corpus
3. Pre-procesar el texto
4. Seleccionar el modelo adecuado
5. Interpretar y validar el modelo
6. Comunicar el modelo.

- Pocos estándares
- Tabla de palabras por tópico
- LDAviz
- Diferentes métricas: relevancia, FREX, exclusividad, etc.
- Tópicos genéricos vs tópicos exclusivos